

Principes fondamentaux de l'entrepôt de données (Data warehouse)







Objectifs du cours

- Expliquez l'architecture en couches d'un entrepôt de données.
- Décrivez le rôle de la zone de transit, de l'ODS et des entrepôts de données.
- Comprendre l'importance des métadonnées et de la gouvernance des données dans les entrepôts de données.
- Comparez différentes stratégies de déploiement : descendante vs ascendante (et hybride).
- Évaluer les avantages et les limites de chaque approche dans des contextes commerciaux réels.

Plan de cours





Introduction

Pourquoi l'entrepôt de données est-il important?

- Données dispersées dans plusieurs systèmes
- Données hétérogènes provenant de différentes sources
- Données incohérentes ou de mauvaise qualité
- Lenteur des analyses et des rapports
- Difficulté à produire des rapports fiables
- Absence d'historique pour analyser l'évolution
- Difficulté à croiser les données de plusieurs systèmes
- Manque de vision globale pour la prise de décision
- Difficulté à assurer la gouvernance et la sécurité des données



Introduction



➔ **Solution : Créer un entrepôt de données**

Transformer les données opérationnelles en informations précieuses → pour une prise de décision plus éclairée.

Données → Informations


Soutiennent les opérations quotidiennes

Orientent l'analyse et la stratégie



De la donnée à la décision

- Données (Data) → représentent le point de départ et sont généralement nombreuses.
- Information → obtenue après la gestion et l'organisation de données (Data Management).
- Connaissance (Knowledge) → construite grâce à l'interprétation des informations dans leur contexte.
- Décision → étape finale, où les connaissances permettent de prendre des décisions pertinentes et stratégiques.





Architecture en couches d'un entrepôt de données

Qu'est-ce qu'un entrepôt de données ?



- Un **entrepôt de données (ED)** est un référentiel centralisé qui consolide les données provenant de multiples sources hétérogènes telles que les bases de données relationnelles, les systèmes transactionnels, les applications CRM et de point de vente, les plateformes ERP, les API externes, les fichiers plats et même les objets connectés. Son objectif principal est de stocker de grands volumes de données de manière structurée et de les rendre facilement accessibles pour **l'analyse, le reporting et la prise de décision**.
- Contrairement aux bases de données traditionnelles optimisées pour les opérations transactionnelles quotidiennes (OLTP), un entrepôt de données est spécifiquement conçu pour **le traitement analytique (OLAP)**. Il prend en charge les requêtes complexes portant sur de vastes volumes de **données historiques**, permettant ainsi aux organisations d'identifier les tendances, d'en extraire des informations et de prendre des décisions commerciales éclairées.

Cas d'utilisation d'un entrepôt de données



■ Les entrepôts de données sont largement utilisés dans divers secteurs d'activité tels que :

- [?] Banque / Finance : analyse des transactions, risques
- [?] Commerce : ventes, clients, stocks
- [?] Santé : patients, soins, statistiques
- [?] Marketing : campagnes, comportement clients
- [?] Logistique : livraisons, stocks, transport
- [🏭] Industrie : production, qualité, performance
- [?] Télécoms : consommation, abonnements, clients

Caractéristiques d'un entrepôt de données



Axé sur le sujet :


- Un entrepôt de données est organisé autour de thématiques clés de l'entreprise (par exemple, clients, produits, ventes, revenus) plutôt que des opérations quotidiennes.
- Il fusionne les données provenant de multiples systèmes opérationnels et domaines d'activité en une vue unifiée du sujet.
- Seules les données pertinentes pour l'objet de l'analyse sont conservées, éliminant les détails inutiles et se concentrant sur l'aide à la décision.

Caractéristiques d'un entrepôt de données



Données intégrées

- Un entrepôt de données consolide et représente les informations provenant de sources diverses et hétérogènes (bases de données, CRM, ERP, fichiers plats, API, etc.).
- L'intégration garantit que les données provenant de différents systèmes respectent des conventions d'appellation, des formats et des unités de mesure cohérents.
- Cette structure unifiée permet une analyse transversale et fournit une version unique de la vérité pour l'ensemble de l'organisation.



Caractéristiques d'un entrepôt de données



Données non volatiles


- Dans un entrepôt de données, les données sont stables : une fois stockées, elles ne peuvent être ni mises à jour ni supprimées.
- Seules les nouvelles informations sont ajoutées (par chargement de données), préservant ainsi l'intégrité historique de l'ensemble de données.
- Cette propriété reflète l'activité commerciale de l'entreprise au cours d'une période donnée.
- Elle garantit la traçabilité, permettant de revenir sur les états passés de l'entreprise et de justifier les décisions prises.
- Contrairement aux systèmes d'exploitation, l'entrepôt de données ne prend pas en charge les opérations d'insertion, de mise à jour ou de suppression ; il ne prend en charge que le chargement et l'interrogation.

Caractéristiques d'un entrepôt de données



Données historiques


- Un entrepôt de données enregistre des informations sur des périodes définies (jours, mois, années).
- Les données sont toujours liées à une dimension temporelle, soit explicitement (champs de date), soit implicitement.
- Une fois stockées, les données ne sont plus mises à jour ; elles restent une image instantanée de l'activité commerciale à ce moment précis.
- Cela permet de constituer un référentiel temporel, permettant aux organisations d'analyser les tendances, les schémas et les changements historiques au fil du temps.
- Elle facilite la prise de décision à long terme en fournissant une perspective historique, contrairement aux bases de données opérationnelles qui se concentrent sur les transactions actuelles.



Qu'est-ce que l'architecture d'un entrepôt de données ?

- L'architecture d'un entrepôt de données sert de plan directeur régissant la circulation des données provenant de sources multiples vers les utilisateurs finaux. Son rôle principal est de garantir que les informations soient *intégrées, structurées et accessibles* pour le traitement analytique et la production de rapports.
- Les données sont généralement transférées vers l'entrepôt via des pipelines *ETL (Extraction, Transformation, Chargement)* ou *ELT (Extraction, Chargement, Transformation)*.
- Malgré ces différences, la plupart des architectures d'entrepôts de données peuvent être décrites en termes de *quatre couches logiques*, chacune ayant un objectif unique :
 1. **Couche source de données / couche d'intégration** – se connecte à des systèmes opérationnels hétérogènes.
 2. **Couche de préparation/transformation** – nettoie, valide et remodèle les données entrantes.
 3. **Couche de stockage/de service de données** – stocke les données intégrées et historiques.
 4. **Couche de présentation** – fournit des données aux utilisateurs finaux via des requêtes, des tableaux de bord et des rappor






Architecture DW

1. Couche source de données

- La **couche source de données** représente le point d'origine de toutes les informations qui alimenteront l'entrepôt de données. Ces sources peuvent être **internes** (comme les bases de données opérationnelles, les systèmes CRM ou ERP) ou **externes** (comme les sites web, les réseaux sociaux ou les services tiers).

Voici quelques exemples :

- Bases de données opérationnelles** (par exemple, MySQL, PostgreSQL, Oracle)
 - Applications cloud** (par exemple, Salesforce, Google Analytics, SAP)
 - Fichiers plats** (ex. : CSV, JSON, XML)
 - API et données en flux continu** (par exemple, pipelines Kafka, flux de données d'appareils IoT)
- Cette couche est cruciale car elle collecte des données brutes provenant de multiples systèmes hétérogènes, constituant ainsi la base des processus d'intégration et de transformation ultérieurs.



Architecture DW



2. Couche de transition (transformation)

- La **zone de transit des données** est une couche intermédiaire de stockage et de traitement située entre les systèmes sources et l'entrepôt de données. Son objectif principal est de collecter les données brutes, d'effectuer un prétraitement et de les préparer à l'intégration dans l'entrepôt de données ou les couches de modélisation.
- En fonction des exigences de conception et commerciales, la mise en scène peut prendre différentes formes :

Mise en scène temporaire (non persistante)

Les données sont chargées, transformées, puis transférées vers l'entrepôt de données.

Les tables de préparation sont souvent tronquées ou supprimées après utilisation.

Courant dans les processus ETL/ELT par lots.

Stade persistant

Les données de préparation historiques sont conservées à des fins d'audit, de débogage ou de retraitement.

Utile pour les **dimensions à évolution lente (SCD)** et les tâches de rapprochement.

Peut servir de zone de transit pour les données brutes avant transformation.

Architecture DW

2. Couche de transition (transformation)

Étapes clés de la préparation des données

1. **Extraction** → Collecter les données depuis les systèmes sources de façon efficace et non intrusive.
2. **Profilage** → Évaluer la qualité des données : complétude, cohérence et anomalies.
3. **Nettoyage** → Corriger les erreurs, supprimer les doublons et traiter les incohérences.
4. **Transformation** → Reformater et restructurer les données selon le schéma cible.
5. **Validation** → Contrôler les données au regard des règles métier.
6. **Intégration** → Fusionner les sources et résoudre les conflits pour obtenir une vue unifiée.
7. **Stockage** → Conserver temporairement ou durablement les données préparées pour contrôle et réutilisation.
8. **Chargement** → Charger les données finalisées dans l'entrepôt ou le système cible.




Architecture DW



3. Couche de stockage des données

- L'entrepôt de données est le composant central de l'architecture — un système centralisé conçu pour stocker des données historiques structurées et prendre en charge l'analyse avancée.
- **Caractéristiques principales :**
 - ✓ **Évolutivité** → Gère efficacement des volumes de données importants et croissants.
 - ✓ **Haute performance** → Permet des requêtes rapides et des tableaux de bord en temps réel.
 - ✓ **Cohérence** → Agit comme une source unique de vérité partagée par tous les départements.
- La couche de stockage des données est chargée dans l'entrepôt de données et, dans certains cas, dans des data marts . Le flux exact dépend de l'architecture.

Architecture DW



- L' **entrepôt de données** = la « *vue d'ensemble* », l'intégration à l'échelle de l'entreprise, la source unique de vérité.
- Le **Data Mart** = une « *vue zoomée* », conçue pour un département ou une fonction métier spécifique.

Architecture DW



Aspect	Entrepôt de données (DW)	Data Mart (DM)
Portée	À l'échelle de l'entreprise (couvre l'ensemble de l'organisation)	Spécifique au département (Ventes, Marketing, Finance)
Taille	À grande échelle (téraoctets à pétaoctets)	Des ensembles de données plus petits et ciblés
But	Référentiel centralisé pour toutes les données de l'entreprise	Optimisé pour des besoins analytiques spécifiques
Source de données	Systèmes multiples et hétérogènes (CRM, ERP, API, IoT, etc.)	Sous-ensemble de l'entrepôt de données ou parfois directement à partir des sources
Gestion	Complexe à mettre en œuvre et à maintenir	Plus facile à gérer et à entretenir
Performance	Peut nécessiter une optimisation pour les requêtes très volumineuses.	Plus rapide pour les requêtes et les rapports ciblés
Coût	Plus élevé (infrastructure + maintenance)	Plus bas, plus rentable

Architecture DW



4. Couche de présentation des données

- La couche de présentation des données est le point où l'information devient directement accessible aux utilisateurs finaux. À ce stade, les données sont organisées, stockées et diffusées sous une forme permettant l'interrogation, la génération de rapports et l'analyse avancée.
- Cette couche permet d'accéder via :
 - ✓ Outils de Business Intelligence (BI) – tableaux de bord, plateformes de reporting et interfaces de visualisation.
 - ✓ Outils d'exploration de données – pour découvrir des tendances et des corrélations.
 - ✓ Requêtes directes – requêtes SQL ou requêtes ad hoc exécutées par des analystes ou des utilisateurs métiers.
 - ✓ Pour les entreprises, la couche de présentation représente l'entrepôt de données lui-même. C'est la seule partie avec laquelle elles interagissent, souvent via des interfaces graphiques qui visualisent les résultats des requêtes et les indicateurs clés de performance (KPI).

Architecture DW




- Les données sont structurées dans l'entrepôt via la préparation, l'ODS et les data marts ; il est tout aussi important de veiller à ce que ces données soient bien documentées et fiables – c'est le rôle des **métadonnées et de la gouvernance des données**.

- **Métadonnées – « données sur les données »**


- ✓ Décrit la structure, la signification et l'utilisation des données d'entrepôt de données.
- ✓ Métadonnées techniques → schémas, tables, ETL, transformation
- ✓ Métadonnées métier → Indicateurs clés de performance (KPI), te
- ✓ Garantit la clarté, la transparence et une compréhension commu

- **Gouvernance des données – gérer les données comme un atout stratégique**

- ✓ Garantit la qualité des données (exactitude, cohérence, exhaustivité)
- ✓ Garantit la sécurité et la conformité (accès, audit, RGPD).
- ✓ Définit les rôles et les responsabilités (propriétaires, intendants, de
- ✓ Renforce la confiance dans l'entrepôt de données pour la prise de décision.



Architecture DW





Stratégies de déploiement (descendante vs ascendante)



Principales architectures d'entrepôt de données

Les organisations peuvent adopter différentes **approches architecturales** lors de la conception d'un entrepôt de données, en fonction de leurs priorités en matière de rapidité, d'intégration et d'évolutivité.


- ❑ **Architecture descendante**

- ❑ **Architecture ascendante**

- ❑ **Architecture hybride**


Architecture d'entrepôt de données descendante

L'approche descendante, concept introduit par **Bill Inmon**, propose une architecture d'entrepôt de données quelque peu différente. Dans ce cas, l'entrepôt de données est construit en premier, puis les data marts dimensionnels sont développés ultérieurement. **Comment ça marche.**



- EDW → Création d'un entrepôt central qui constitue la source unique de vérité.
- Intégration des données → Les données sont collectées, nettoyées, transformées et chargées dans l'EDW.
- Entrepôts dépendants → Création de Data Marts spécialisés à partir de l'EDW pour répondre aux besoins de chaque département.

Architecture d'entrepôt de données descendante



Architecture de base d'entrepôt de données de Bill Inmon



Avantages de la méthode Inmon

- L'approche de conception de Bill Inmon offre les avantages suivants :
 - ✓ L'entrepôt de données sert de source unique de vérité pour l'ensemble de l'entreprise, où toutes les données sont intégrées.
 - ✓ Cette approche présente une très faible redondance des données. Par conséquent, le risque d'irrégularités dans la mise à jour des données est réduit, ce qui simplifie le processus d'entrepôt de données basé sur le concept ETL et le rend moins sujet aux pannes.
 - ✓ Il simplifie les processus métier, car le modèle logique représente des objets métier détaillés.
 - ✓ Cette approche offre une plus grande flexibilité, car il est plus facile de mettre à jour l'entrepôt de données en cas de changement dans les besoins de l'entreprise ou dans les données sources.
 - ✓ Il peut gérer diverses exigences en matière de rapports à l'échelle de l'entreprise.

Inconvénients de la méthode Inmon

Les inconvénients possibles de cette approche sont les suivants :

- ✗ La complexité augmente à mesure que de multiples tables sont ajoutées au modèle de données au fil du temps.
- ✗ Des ressources qualifiées en modélisation de données d'entrepôt de données sont nécessaires, ce qui peut s'avérer coûteux et difficile à trouver.
- ✗ La mise en place et la livraison préliminaires prennent du temps.
- ✗ Une opération de processus ETL supplémentaire est nécessaire car les data marts sont créés après la création de l'entrepôt de données.
- ✗ Cette approche nécessite l'intervention d'experts pour gérer efficacement un entrepôt de données.





Architecture d'entrepôt de données ascendante


Architecture ascendante — Approche de Kimball

Les Data Marts sont créés en premier pour répondre aux besoins spécifiques des différents domaines, puis intégrés progressivement dans un EDW centralisé.


Comment ça marche ?

- 1. Data Marts départementaux** → Création de Data Marts dédiés à chaque domaine métier.
- 2. Accès direct aux données** → Extraction des données depuis les sources opérationnelles pour répondre rapidement aux besoins d'analyse.
- 3. Intégration progressive** → Regroupement des Data Marts au sein d'un EDW centralisé.
- 4. Évolution continue** → Architecture flexible qui s'adapte aux priorités et besoins métiers.

Architecture d'entrepôt de données ascendante



Architecture d'entrepôt de données ascendante



Architecture de base d'un entrepôt de données Kimball

Avantages de la méthode Kimball

Avantage	Description
Construction rapide	La modélisation dimensionnelle simplifie la conception et accélère la mise en place de l'entrepôt.
Schéma en étoile convivial	Structure intuitive et facile à comprendre, facilitant les requêtes et l'analyse pour les utilisateurs métiers.
Empreinte système réduite	L'approche se concentre sur des processus métier spécifiques, réduisant le stockage et la complexité du système.
Récupération efficace des données	L'organisation en tables de faits et de dimensions permet des requêtes rapides et efficaces.
Besoins en ressources réduits	Une équipe plus restreinte peut gérer le système grâce à une architecture orientée processus et à une optimisation prévisible.
Dimensions conformes & qualité des données	Les dimensions conformes favorisent la cohérence et la qualité des données entre les différents schémas en étoile.

Inconvénients de la méthode Kimball



- ✗ Les données ne sont pas entièrement intégrées avant la publication des rapports ; l'idée d'une « source unique de vérité » est perdue.
- ✗ Des irrégularités peuvent survenir lors de la mise à jour des données dans une architecture d'entrepôt de données Kimball. Cela est dû au fait que, lors de la dénormalisation, des données redondantes sont ajoutées aux tables de la base de données.
- ✗ Dans l'architecture Kimball DW, l'ajout de colonnes à la table de faits peut engendrer des problèmes de performance, ces tables étant très profondes. En effet, l'ajout de nouvelles colonnes peut augmenter le nombre de dimensions de la table de faits et impacter ses performances. De plus, le modèle d'entrepôt de données dimensionnel devient difficile à adapter à l'évolution des besoins métiers.
- ✗ Le modèle Kimball étant axé sur les processus métier plutôt que sur l'entreprise dans son ensemble, il ne peut pas répondre à toutes les exigences en matière de reporting décisionnel.
- ✗ Le processus d'intégration de grandes quantités de données existantes dans l'entrepôt de données est complexe.


Architecture d'entrepôt de données hybride

Architecture hybride : le meilleur des approches Top-Down & Bottom-Up

Une approche équilibrée combinant gouvernance et intégration à l'échelle de l'entreprise avec agilité et rapidité d'analyse métier.

Les principaux atouts

1. **Cohérence & gouvernance** → Un cadre centralisé garantissant la qualité et l'uniformité des données.
2. **Agilité métier** → Des data marts adaptés aux besoins spécifiques des départements.
3. **Évolutivité** → Une architecture capable d'accompagner la croissance et l'évolution des besoins.
4. **Rapidité & flexibilité** → Des réponses analytiques rapides grâce à des environnements décentralisés





Architecture d'entrepôt de données hybride

❓ Fonctionnement

1. EDW centralisé → Garantit la cohérence, la qualité et la gouvernance des données à l'échelle de l'entreprise.
2. Data marts départementaux → Répondent rapidement aux besoins spécifiques d'analyse et de reporting des métiers.
3. Interopérabilité → Assure une circulation fluide des données entre le socle central et les environnements métiers.
4. Harmonisation progressive → Favorise la standardisation, renforce l'intégration et réduit progressivement les redondances.


Comparaison des architectures d'entrepôts de données

Facteur	De haut en bas	De bas en haut	Hybride
Concentration initiale	Construisez d'abord l'entrepôt de données d'entreprise, puis les data marts.	Créez des entrepôts de données départementaux, puis intégrez-les pour créer un entrepôt de données.	Développement parallèle d'entrepôts de données et de data marts d'entreprise
Rapidité de mise en valeur	Plus lent — valeur perçue après la construction de l'EDW	Rapide — des gains rapides grâce aux premiers data marts	Modéré — gains rapides initiaux et intégration à long terme
Gouvernance	Contrôle centralisé et normes strictes	Décentralisé, varie selon le département	Équilibré — règles d'entreprise avec flexibilité locale
Évolutivité	Hautement évolutif, idéal pour une croissance à long terme	L'échelle s'adapte à chaque nouveau data mart, une réorganisation peut être nécessaire.	Facilement extensible, s'adapte à la croissance de l'entreprise
Coût/Ressources	Investissement initial élevé, retour sur investissement plus long	Coût initial plus faible, dépenses itératives	Investissement échelonné, étalant les coûts dans le temps
Engagement des utilisateurs	Saisie utilisateur après livraison DW	Retour d'information continu, alignement étroit avec les utilisateurs	Un engagement à tous les niveaux, avec la contribution des instances centrales et locales.
Idéal pour	Les organisations qui ont besoin d'analyses d'entreprise unifiées	Environnements en constante évolution nécessitant rapidité et agilité	Les entreprises qui ont besoin à la fois de flexibilité et de gouvernance
Démérites	Délai de retour sur investissement plus long, forte intensité de ressources	Risque de cloisonnement, complexité de l'intégration	Plus complexe à concevoir et à intégrer, elle nécessite des équipes qualifiées.

Quelle approche d'entrepôt de données choisir ?

Critère	Top-Down	Bottom-Up	Hybride ☆
Gouvernance	☆☆☆ Forte	☆ Faible	☆☆☆ Forte
Rapidité de mise en œuvre	☆☆	☆☆☆	☆☆☆
Flexibilité métier	☆☆	☆☆☆	☆☆☆
Vision globale	☆☆☆	☆☆	☆☆☆
Évolutivité	☆☆☆	☆☆	☆☆☆
Complexité	Élevée	Faible	Moyenne

➔ L'approche hybride apparaît comme le choix le plus adapté pour concilier vision stratégique, gouvernance et besoins opérationnels.



Conclusion

- 
- Un **entrepôt de données (DW)** est l'épine dorsale de la Business Intelligence, intégrant des données hétérogènes dans un référentiel centralisé et fiable.
 - Son **architecture en couches** (Staging → ODS → DW → Data Marts) garantit que les données sont correctement nettoyées, organisées et adaptées aux besoins de l'entreprise et des départements.
 - **Les métadonnées** fournissent la documentation et le contexte, tandis que **la gouvernance des données** garantit la qualité, la sécurité et la fiabilité de l'entrepôt de données.
 - différentes **stratégies de déploiement** :
 - ✓ **Approche descendante (Inmon)** → cohérence et gouvernance à long terme.
 - ✓ **Bottom-Up (Kimball)** → livraison rapide et agilité.
 - ✓ **Hybride** → équilibre entre les deux.
 - Le choix de la bonne approche dépend des **priorités, des ressources et des besoins en matière de rapports de l'organisation**.



Questions

pédagogie@caplogy.com